

Informe de evaluacion de IA para Sparta Ledger

Documentos, motos adjudicadas y modulo Sabueso - Junio 2026

1. Resumen ejecutivo

Se evaluaron dos caminos: contratar una IA por API o rentar un servidor con GPU para correr un modelo open-source. La recomendacion practica es iniciar con una API de IA para validar el flujo rapidamente y, en paralelo, dejar el sistema preparado para migrar a un modelo open-source si el volumen de evidencias/documentos justifica el costo de infraestructura.

Recomendacion principal para una sola contratacion: usar **Gemini 2.5 Flash** si se busca mejor equilibrio entre calidad, costo, soporte, vision, texto, video y facilidad de integracion. Si la prioridad absoluta es costo por documento/imagen y la empresa acepta Alibaba Cloud, **Qwen-VL-Plus / Qwen-VL-OCR** es la opcion mas barata y muy alineada a documentos visuales. No se recomienda Claude como primera opcion por costo.

Recomendacion para servidor propio: Qwen2.5-VL-32B-Instruct sobre una GPU de 48 GB VRAM. Para piloto barato puede usarse Qwen2.5-VL-7B en 24 GB VRAM, pero con menor calidad. Para maxima calidad local, Qwen2.5-VL-72B requiere 80 GB VRAM o mas.

2. Casos de uso que debe cubrir la IA

Modulo	Tareas esperadas de IA	Tipo de entrada	Salida esperada
Capital Humano / Documentos	Identificar documento, leer datos, validar vigencia, comparar nombre/CURP/RFC, detectar documentos ilegibles o incompletos.	PDF, imagen, escaneo, foto de baja calidad.	JSON con aprobado/rechazado, confianza, motivos y campos detectados.
Motos adjudicadas	Analizar evidencias, detectar dano visible, estado general, faltantes, placas/serie visibles, calidad de evidencia.	Fotos, videos, comentarios del gestor.	Dictamen de condicion, lista de danos, evidencia insuficiente, riesgo y recomendacion.
Sabueso	Leer dictamen de gestor, clasificar resultado, sugerir siguiente accion, priorizar casos, detectar ilocalizable y recomendar asignacion.	Texto, historial, ubicaciones, bitacora, resultados previos.	Decision sugerida, razonamiento resumido, acciones y bitacora auditable.

3. Comparativa de alternativas pagadas por API

Proveedor / modelo	Precio aproximado	Fortalezas	Riesgos / notas	Recomendacion
Google Gemini 2.5 Flash	\$0.30 input / \$2.50 output por 1M tokens. Flash-Lite baja a \$0.10 input / \$0.40 output.	Muy buen costo/calidad; soporta texto, imagen, video, salidas estructuradas y alto contexto.	Datos salen a proveedor externo; revisar políticas de privacidad y region.	Mejor opcion unica balanceada.
Alibaba Qwen-VL-Plus / Qwen-VL-OCR	Qwen-VL-Plus: \$0.115 input / \$0.287 output por 1M tokens. Qwen-VL-OCR: \$0.043 input / \$0.072 output.	Muy barato; fuerte en documentos, OCR visual y vision. Alineado con Qwen2.5/Qwen3-VL.	Menor ecosistema empresarial local que Google/OpenAI; revisar region, soporte, cumplimiento y confianza interna.	Mejor opcion si manda el costo.
OpenAI GPT-5.4 mini / GPT-5.4	Mini: \$0.75 input / \$4.50 output. GPT-5.4: \$2.50 input / \$15 output.	Muy buen ecosistema para agentes, herramientas, JSON, integracion y auditoria.	Mas caro que Gemini Flash y Qwen para alto volumen visual/documental.	Bueno, pero no el mas barato.
Anthropic Claude Sonnet / Opus	Sonnet 4.6: \$3 input / \$15 output. Opus 4.8: \$5 input / \$25 output.	Alta calidad de razonamiento y redaccion.	Costo elevado para procesar evidencias, fotos y documentos a gran volumen.	No recomendado por costo inicial.

4. Opcion open-source en servidor propio

El modelo open-source recomendado es **Qwen2.5-VL**. La familia tiene variantes de 3B, 7B, 32B y 72B parametros. Qwen2.5-VL declara capacidades utiles para el proyecto: analisis visual de texto, graficas, iconos y layouts; localizacion de objetos; salidas JSON estables con coordenadas/atributos; y extraccion estructurada desde facturas, formularios y tablas.

Nivel	Modelo sugerido	GPU minima recomendable	Costo 24/7 estimado	Uso recomendado
Piloto economico	Qwen2.5-VL-7B cuantizado	24 GB VRAM: L4, RTX 4090, A5000	L4 \$0.39 USD/hr = \$284.70 USD/mes; RTX 4090 \$0.69 USD/hr = \$503.70 USD/mes	Pruebas con documentos y fotos; no ideal para decisiones criticas.
Produccion inicial recomendada	Qwen2.5-VL-32B cuantizado	48 GB VRAM: RTX A6000, RTX 6000 Ada, L40S	RTX A6000 \$0.49 USD/hr = \$357.70 USD/mes; RTX 6000 Ada \$0.77 USD/hr = \$562.10 USD/mes	Mejor balance local para documentos, evidencias y dictámenes.
Alta calidad local	Qwen2.5-VL-72B cuantizado	80 GB VRAM: A100/H100 o superior	A100 80GB \$1.39 USD/hr = \$1,014.70 USD/mes; H100 80GB \$2.89 USD/hr = \$2,109.70 USD/mes	Casos complejos, video/evidencias pesadas y mejor razonamiento visual.

A estos costos se debe sumar almacenamiento persistente, backups, transferencia, administracion, monitoreo y tiempo tecnico. En RunPod, el almacenamiento indicado publicamente parte de \$0.10/GB/mes para container/volume disk y \$0.07/GB/mes para network storage estandar bajo 1 TB.

5. Decision recomendada

Escenario	Decision recomendada	Motivo
Se requiere resultado rapido, bajo riesgo tecnico y una sola contratacion	Contratar Gemini 2.5 Flash	Cubre texto, imagen y video; tiene buen costo, salidas estructuradas y ecosistema maduro.
El presupuesto es el factor principal y se acepta proveedor chino/global	Contratar Alibaba Qwen-VL-Plus y evaluar Qwen-VL-OCR	Costo por token mucho menor, especialmente para documentos y OCR visual.
Se busca privacidad y control de datos a mediano plazo	Rentar GPU 48 GB y montar Qwen2.5-VL-32B	Los documentos no salen del entorno controlado; costo fijo mensual si hay mucho volumen.
Se planeaba Claude	No usar Claude como primera opcion de produccion masiva	Su costo por 1M tokens es alto comparado con Gemini Flash y Qwen; puede reservarse para casos excepcionales.

6. Arquitectura propuesta para no quedar amarrados

Aunque se contrate una sola IA, el sistema debe integrarse mediante un **Servicio IA interno**. Este servicio recibe documentos, fotos, textos y datos del sistema; llama al proveedor seleccionado; y devuelve siempre un JSON propio de Sparta Ledger. Asi se evita reescribir los modulos si mas adelante se cambia de Gemini a Qwen local, OpenAI o Alibaba.

Componente	Funcion
ai_jobs	Cola de trabajos: documento, evidencia de moto, dictamen Sabueso.
ai_provider	Adaptador unico: Gemini, Alibaba Qwen, OpenAI o Qwen local.
ai_results	Guarda JSON, confianza, version de prompt, modelo usado, costo estimado y evidencia.
ai_audit_log	Bitacora de decisiones: que vio la IA, que recomendo y que accion se ejecuto.
human_review_queue	Casos de baja confianza o alto riesgo pasan a revision humana.

7. Control y seguridad

La IA no debe tener permiso directo e ilimitado para modificar la operacion. Debe iniciar como recomendador, con acciones automaticas solo cuando la confianza sea alta y las reglas internas lo permitan. Toda decision debe quedar en bitacora con evidencia y explicacion.

Riesgo	Control recomendado
Error de interpretacion	Umbrales de confianza y revision humana obligatoria en casos dudosos.
Datos personales sensibles	Politica de privacidad, cifrado, retencion limitada y control de proveedor/regiones.
Costo variable	Presupuesto mensual, limites por modulo y monitoreo por solicitud.
Automatizacion incorrecta	Primero recomendaciones; despues automatizacion gradual por reglas.

8. Conclusiones

La opcion mas segura para avanzar rapido es contratar un solo proveedor de IA y construir el Servicio IA interno. Si la empresa quiere el mejor balance general, se recomienda Gemini 2.5 Flash. Si el objetivo principal es demostrar ahorro frente a Claude, Alibaba Qwen-VL-Plus/Qwen-VL-OCR ofrece precios considerablemente menores y esta muy orientado a documentos visuales.

Para servidor propio, Qwen2.5-VL-32B sobre GPU de 48 GB es la recomendacion realista. El costo 24/7 estimado en proveedores GPU tipo RunPod va de aproximadamente \$358 a \$562 USD/mes para GPUs de 48 GB, mas almacenamiento y operacion. Este camino conviene cuando el volumen mensual sea alto o cuando la privacidad de documentos sea

prioritaria.

9. Fuentes consultadas

OpenAI API Pricing: <https://openai.com/api/pricing/>

Anthropic Claude API Pricing: <https://platform.claude.com/docs/en/about-claude/pricing>

Google Gemini API Pricing: <https://ai.google.dev/gemini-api/docs/pricing>

Google Gemini Vision / Image understanding: <https://ai.google.dev/gemini-api/docs/image-understanding>

Alibaba Cloud Model Studio - Qwen-VL pricing/capabilities: <https://www.alibabacloud.com/help/en/model-studio/models>

Qwen2.5-VL-32B-Instruct model card: <https://huggingface.co/Qwen/Qwen2.5-VL-32B-Instruct>

Qwen2.5-VL-72B-Instruct model card: <https://huggingface.co/Qwen/Qwen2.5-VL-72B-Instruct>

RunPod GPU pricing: <https://www.runpod.io/pricing>

AWS EC2 G6 instance specs: <https://aws.amazon.com/ec2/instance-types/g6/>

Nota: precios en USD consultados el 18 de junio de 2026. Los costos pueden cambiar por region, impuestos, descuentos, almacenamiento, trafico, modo batch/serverless y disponibilidad de GPU. Antes de contratar se recomienda confirmar cotizacion final con el proveedor.