

Informe directo: IA recomendada para Sparta Ledger

Version ejecutiva - 18 de junio de 2026

1. Decision recomendada

Recomendacion #1 por calidad/precio: Gemini 3.5 Flash. Es oficial en Gemini API, estable, multimodal y sirve para documentos, fotos, video, dictámenes y agentes. Es la mejor compra unica si queremos menos riesgo tecnico.

Recomendacion #2 si se prefiere IA china barata: Alibaba Qwen3.5-Plus para calidad y Qwen3.5-Flash para volumen barato. Alibaba declara soporte texto, imagen y video; es la alternativa china mas completa y con precios claros.

No recomiendo Claude como primera opcion: es muy bueno, pero para procesar documentos/fotos/videos todos los dias sale caro. Mejor dejarlo fuera o usarlo solo para casos muy complejos.

2. Comparativa rapida de APIs

Opcion	Sirve para lo que queremos	Costo oficial aprox. por 1M tokens	Veredicto
Gemini 3.5 Flash	Si: texto, imagen, video, agentes, documentos, JSON.	Google lista Gemini 3.5 en modelos actuales. En Gemini 3.x hay precios desde \$0.125-\$0.45 input y \$0.75-\$2.70 output segun modo/modelo.	Mejor balance general.
Alibaba Qwen3.5-Plus	Si: texto, imagen y video. Muy fuerte para documento/evidencia visual.	Global: desde \$0.115 input / \$0.688 output. Qwen3.5-Flash desde \$0.029 input / \$0.287 output.	Mejor opcion china costo/calidad.
DeepSeek V4	Parcial: excelente para texto, JSON y herramientas. No es mi primera opcion para fotos/evidencias porque su API oficial de pricing no muestra vision.	\$0.14 input / \$0.28 output en V4-Flash; \$0.435 input / \$0.87 output en V4-Pro.	Barato para Sabueso/texto; no como IA unica.
Kimi K2.6 / Moonshot	Si: declara texto, imagen, video, agentes, JSON y tool calls.	Pricing publico visto, pero la pagina no mostro tabla numerica clara en la captura; requiere confirmar en consola/cotizacion.	Prometedor; no lo pondria #1 sin cotizar.
Z.ai GLM-4.5V / 4.6V	Fuerte en vision open-source; bueno para servidor propio.	Pricing API no tan claro en fuentes publicas; como modelo abierto compite para self-host.	Bueno para piloto local/open-source.
OpenAI GPT-5.4 mini	Si: muy buen ecosistema, vision y herramientas.	\$0.75 input / \$4.50 output; GPT-5.4 sube a \$2.50 / \$15.	Bueno, pero mas caro que Gemini/Qwen.
Claude Sonnet / Haiku	Si: buen razonamiento y vision.	Haiku 4.5: \$1 / \$5. Sonnet 4.6: \$3 / \$15. Opus 4.8: \$5 / \$25.	Calidad alta, costo alto.

3. Servidor propio con modelo open-source

Si se quiere que los documentos no salgan del servidor, se puede montar un modelo open-source. Pero requiere GPU; en CPU seria demasiado lento para produccion.

Nivel	Modelo viable	GPU recomendada	Costo RunPod 24/7 aprox.	Comentario
Piloto barato	Qwen2.5-VL-7B / GLM-4.1V-9B / Kimi-VL	24 GB VRAM	L4 \$0.39/hr = \$285/mes; RTX A5000 \$0.27/hr = \$197/mes	Sirve para pruebas; calidad menor.
Produccion inicial	Qwen2.5-VL-32B o GLM-4.5V cuantizado	48 GB VRAM	RTX A6000 \$0.49/hr = \$358/mes; RTX 6000 Ada \$0.77/hr = \$562/mes	Recomendado si quieren IA propia.
Alta calidad local	Qwen2.5-VL-72B / modelos VLM grandes	80 GB VRAM	A100 80GB \$1.39/hr = \$1015/mes; H100 \$2.89/hr = \$2110/mes	Mas caro; mejor para mucho volumen.

4. Conclusion directa para direccion

Pregunta	Respuesta
Que contratamos si solo puede ser una IA?	Gemini 3.5 Flash. Es la opcion mas equilibrada, menos riesgosa y sirve para documentos, motos y Sabueso.
Que IA china conviene revisar?	Alibaba Qwen3.5-Plus / Qwen3.5-Flash. Tiene precios bajos y soporte multimodal claro. DeepSeek es barato, pero lo usaria para texto, no como IA visual unica.
Servidor propio conviene?	Solo si el volumen mensual sera alto o si por privacidad no se quiere mandar documentos a terceros. Para empezar, no es lo mas rapido.
Claude conviene?	No como primera opcion por costo. Puede ser excelente, pero no es la mejor compra para alto volumen documental/visual.

Pregunta	Respuesta
Como integrarlo?	Crear un Servicio IA interno con JSON, bitacora, confianza y proveedor intercambiable. Asi cambiamos de IA sin rehacer todo.

5. Ruta sugerida

- Fase 1: piloto de 30 días con Gemini 3.5 Flash o Alibaba Qwen3.5-Plus sobre documentos, evidencias de moto y dictámenes Sabueso.
- Fase 2: medir costo real por caso, porcentaje de acierto y casos enviados a revision humana.
- Fase 3: automatizar solo decisiones de alta confianza; el resto queda para supervisor.
- Fase 4: si el volumen crece, montar Qwen/GLM local en GPU de 48 GB y dejar API externa solo como respaldo.

Fuentes principales

Google Gemini models: <https://ai.google.dev/gemini-api/docs/models>

Google Gemini pricing: <https://ai.google.dev/gemini-api/docs/pricing>

Alibaba Model Studio models/prices: <https://www.alibabacloud.com/help/en/model-studio/models>

DeepSeek pricing: https://api-docs.deepseek.com/quick_start/pricing

Kimi K2.6 capabilities: <https://platform.kimi.ai/docs/pricing/chat-k26>

OpenAI pricing: <https://openai.com/api/pricing/>

Claude pricing: <https://platform.claude.com/docs/en/about-claude/pricing>

RunPod GPU pricing: <https://www.runpod.io/pricing>

Qwen2.5-VL-32B: <https://huggingface.co/Qwen/Qwen2.5-VL-32B-Instruct>

GLM-4.5V technical report: <https://arxiv.org/abs/2507.01006>

Nota: precios en USD consultados el 18 de junio de 2026. Confirmar cotizacion final antes de contratar.